
분류/회귀 데이터 셋 지도학습

팀	DF_3조
---	-------

분류 데이터셋

- 데이터셋 명

kaggle - Diabetes Health Indicators Dataset
- 데이터 배경

당뇨병은 대표적인 만성 질환으로, 조기 발견과 생활 습관 개선을 통해 예방 및 관리가 가능하다.

본 데이터는 미국 CDC의 BRFSS 2015 설문조사를 기반으로 한 헬스케어 데이터로, 개인의 건강 상태와 생활 습관 정보를 포함한다.
- 프로젝트 목표

당뇨 위험군 예측하는 분류 모델 구축 : Class 0 (정상) / Class1 (당뇨 위험군)
- 데이터셋 명

diabetes_binary_health_indicators_BRFSS2015.csv

diabetes_binary_5050split_health_indicators_BRFSS2015.csv	diabetes_binary_health_indicators_BRFSS2015.csv	diabetes_012_health_indicators_BRFSS2015.csv
2clss 분류	2class 분류	3class 분류
7만개 데이터	25만개의 데이터	25만개 데이터
클래스 불균형 X	클래스 불균형 0	클래스 불균형 0

데이터 특징

25,3680 rows x 22 columns

```
> class 'pandas.DataFrame'>
RangeIndex: 253680 entries, 0 to 253679
Data columns (total 22 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Diabetes_binary                       253680 non-null float64
1   HighBP                               253680 non-null float64
2   HighChol                             253680 non-null float64
3   CholCheck                            253680 non-null float64
4   BMI                                  253680 non-null float64
5   Smoker                               253680 non-null float64
6   Stroke                               253680 non-null float64
7   HeartDiseaseorAttack                 253680 non-null float64
8   PhysActivity                         253680 non-null float64
9   Fruits                              253680 non-null float64
10  Veggies                             253680 non-null float64
11  HvyAlcoholConsump                   253680 non-null float64
12  AnyHealthcare                       253680 non-null float64
13  NoDocbcCost                         253680 non-null float64
14  GenHlth                             253680 non-null float64
15  MentHlth                            253680 non-null float64
16  PhysHlth                            253680 non-null float64
17  DiffWalk                            253680 non-null float64
18  Sex                                  253680 non-null float64
19  Age                                  253680 non-null float64
20  Education                           253680 non-null float64
21  Income                              253680 non-null float64
dtypes: float64(22)
memory usage: 42.6 MB
```

Diabetes_binary 타겟 변수 Y 설정

당뇨 위험군을 나타내는 변수

0 : 정상


1 : 당뇨 위험군

Null 결측치 없음

```
df.isnull()
```

[illegible]

데이터 불균형



	0 (정상)	1 (당뇨 위험군)
데이터 개수	218334	35346
데이터 확률	86%	14%

데이터에서 정상이 86%로 대부분을 차지하기 때문에, 단순 0만 예측해도 높은 정확도가 나올 가능성이 있고, 1(당뇨 위험군) 데이터를 제대로 학습하지 못할 확률이 큼

=> 소수 클래스에 가중치를 부여하거나, 평가 지표를 Accuracy대신 Recall(재현율), F1-score 활용하여 불균형 문제 해결

회귀 데이터셋

데이터셋 명	kaggle - Starbucks Customer Ordering Patterns
데이터 배경	주문 채널(모바일 앱, 드라이브 스루, 매장, 키오스크), 고객 연령대, 주문시간, 품목 수 및 맞춤설정 등을 반영하여 스타벅스 고객의 주문 패턴을 분석하기 위해 생성된 시뮬레이션 데이터
데이터 특징	총 100,000건의 거래 데이터를 포함하며,, 2024 ~ 2025년(2년)의 기간을 반영. 디지털 벤티 효과(Digital Venti Effect)를 포함하여 모바일 앱 사용자가 기존 매장 구매자에 비해 평균 주문 금액, 맞춤 설정 빈도가 더 높으며, 연령별 이용 양상이 뚜렷.
프로젝트 목표	1. 시간대, 매장 위치 유형, 커스텀 횟수 등의 데이터를 통해 고객의 총 지출액(total_spend)을 예측하는 회귀 모델 구축. 2. 총 지출액(매출)을 가장 잘 예측하는 핵심 요인 도출 및 '디지털 벤티 효과' 등 고객 주문 패턴에 대한 비즈니스 인사이트 확보.
데이터셋 명	starbucks_customer_ordering_patterns.csv

데이터 특징

100,000 rows × 20 columns


```
<class 'pandas.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 20 columns):
#   Column                Non-Null Count  Dtype
---  -
0   customer_id           100000 non-null  str
1   order_id              100000 non-null  str
2   order_date            100000 non-null  str
3   order_time            100000 non-null  str
4   day_of_week           100000 non-null  str
5   order_channel         100000 non-null  str
6   store_id              100000 non-null  str
7   store_location_type   100000 non-null  str
8   region                100000 non-null  str
9   customer_age_group    100000 non-null  str
10  customer_gender        100000 non-null  str
11  is_rewards_member      100000 non-null  bool
12  cart_size             100000 non-null  int64
13  num_customizations     100000 non-null  int64
14  total_spend            100000 non-null  float64
15  fulfillment_time_min   100000 non-null  float64
16  drink_category         100000 non-null  str
17  has_food_item          100000 non-null  bool
18  order_ahead            100000 non-null  bool
19  customer_satisfaction  100000 non-null  int64
dtypes: bool(3), float64(2), int64(3), str(12)
memory usage: 13.3 MB
```

total_spend 타겟 변수 Y 설정

총 지출액 예측

Null 결측치 없음

이상치 확인



count	100000.000000
mean	14.866771
std	5.506800
min	3.510000
25%	10.837500
50%	14.170000
75%	18.180000
max	40.310000

평균 값들 보다 튀는 값(35~40) 이상치가 전체 모델을 왜곡할 가능성 있음

=> 추후 제거 필요