
분류/회귀 데이터 셋 지도학습

팀	DF_3조
---	-------

분류 데이터셋

- 데이터셋 명

kaggle - Diabetes Health Indicators Dataset
- 데이터 배경

당뇨병은 대표적인 만성 질환으로, 초기 발견과 생활 습관 개선을 통해 예방 및 관리가 가능하다.

본 데이터는 미국 CDC의 BRFSS 2015 설문조사를 기반으로 한 헬스케어 데이터로, 개인의 건강 상태와 생활 습관 정보를 포함한다.
- 프로젝트 목표

당뇨 위험군 예측하는 분류 모델 구축 : Class 0 (정상) / Class1 (당뇨 위험군)
- 데이터셋 명

diabetes_binary_health_indicators_BRFSS2015.csv

diabetes_binary_5050split_health_indicators_BRFSS2015.csv	diabetes_binary_health_indicators_BRFSS2015.csv	diabetes_012_health_indicators_BRFSS2015.csv
2clss 분류	2class 분류	3class 분류
7만개 데이터	25만개의 데이터	25만개 데이터
클래스 불균형 X	클래스 불균형 0	클래스 불균형 0

데이터 특징

25,3680 rows x 22 columns

```
> class 'pandas.DataFrame'>
RangeIndex: 253680 entries, 0 to 253679
Data columns (total 22 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Diabetes_binary                       253680 non-null float64
1   HighBP                               253680 non-null float64
2   HighChol                             253680 non-null float64
3   CholCheck                            253680 non-null float64
4   BMI                                  253680 non-null float64
5   Smoker                               253680 non-null float64
6   Stroke                               253680 non-null float64
7   HeartDiseaseorAttack                 253680 non-null float64
8   PhysActivity                         253680 non-null float64
9   Fruits                              253680 non-null float64
10  Veggies                              253680 non-null float64
11  HvyAlcoholConsump                   253680 non-null float64
12  AnyHealthcare                       253680 non-null float64
13  NoDocbcCost                         253680 non-null float64
14  GenHlth                             253680 non-null float64
15  MentHlth                            253680 non-null float64
16  PhysHlth                            253680 non-null float64
17  DiffWalk                            253680 non-null float64
18  Sex                                  253680 non-null float64
19  Age                                  253680 non-null float64
20  Education                            253680 non-null float64
21  Income                              253680 non-null float64
dtypes: float64(22)
memory usage: 42.6 MB
```

Diabetes_binary 타겟 변수 Y 설정

당뇨 위험군을 나타내는 변수

0 : 정상


1: 당뇨 위험군

Null 결측치 없음

```
df.isnull()
```

[illegible]

데이터 불균형




	0 (정상)	1 (당뇨 위험군)
데이터 개수	218334	35346
데이터 확률	86%	14%

데이터에서 정상이 86%로 대부분을 차지하기 때문에, 단순 0만 예측해도 높은 정확도가 나올 가능성이 있고, 1(당뇨 위험군) 데이터를 제대로 학습하지 못할 확률이 큼


=> 소수 클래스에 가중치를 부여하거나, 평가 지표를 Accuracy 대신 Recall(재현율), F1-score 활용하여 불균형 문제 해결

데이터 전처리 단계



새로운 파생 변수 생성

- 질병과 관련된 독립변수(HighBP, HighChol, HeartDiseaseorAttack)들을 합하여 새로운 독립변수(Risk_Sum) 생성




불필요한 변수 삭제

- 상관계수 분석을 통해 종속변수와의 관계가 매우 낮은 변수(AnyHealthcare)를 제거



독립 변수(X) 및 종속 변수(Y)

- 종속변수(Y)는 당뇨 여부를 나타내는 Diabetes_binary로 설정
- 새로운 변수 및 불필요한 변수를 삭제한 나머지 변수들을 독립변수로 구성



새로운 데이터프레임에 저장

- 전처리된 데이터를 새로운 데이터프레임으로 저장

	Diabetes_binary
Diabetes_binary	1.000000
GenHlth	0.293569
HighBP	0.263129
DiffWalk	0.218344
BMI	0.216843
HighChol	0.200276
Age	0.177442
HeartDiseaseorAttack	0.177282
PhysHlth	0.171337
Stroke	0.105816
MentHlth	0.069315
CholCheck	0.064761
Smoker	0.060789
NoDocbcCost	0.031433
Sex	0.031430
AnyHealthcare	0.016255
Fruits	-0.040779
Veggies	-0.056584
HvyAlcoholConsump	-0.057056
PhysActivity	-0.118133
Education	-0.124456
Income	-0.163919

상관관계 확인

corr()함수를 이용하여 독립변수 분석

- 상관관계가 큰 변수중 질병 변수(HighBP, HighChol, HeartDiseaseorAttack)를 합하여 새로운 변수 Risk_Sum생성
- 상관계수 분석을 통해 종속변수와의 상관계수관계가 매우 낮은 변수(AnyHealthcare)를 제거

독립변수와 종속변수 분리

독립변수와 종속변수 분리

```
# 독립변수 X / 종속변수 Y
X = df_cleaned.drop('Diabetes_binary', axis=1).copy()
Y = df_cleaned['Diabetes_binary'].copy()
```

새로운 데이터 프레임에 저장

```
#데이터 전처리 후 새로운 데이터 프레임에 저장
df_cleaned.to_csv('diabetes_processed.csv', index=False)
```

HighBP
HighChol
CholCheck
BMI
Smoker
Stroke
HeartDiseaseorAttack
PhysActivity
Fruits
Veggies
HvyAlcoholConsump
NoDocbcCost
GenHlth
MentHlth
PhysHlth
DiffWalk
Sex
Age
Education
Income
Risk_Sum

→ 최종 독립변수

Diabetes_binary

→ 최종 종속변수

회귀 데이터셋

데이터셋 명	kaggle - Starbucks Customer Ordering Patterns
데이터 배경	주문 채널(모바일 앱, 드라이브 스루, 매장, 키오스크), 고객 연령대, 주문시간, 품목 수 및 맞춤설정 등을 반영하여 스타벅스 고객의 주문 패턴을 분석하기 위해 생성된 시뮬레이션 데이터
데이터 특징	총 100,000건의 거래 데이터를 포함하며,, 2024 ~ 2025년(2년)의 기간을 반영. 디지털 벤티 효과(Digital Venti Effect)를 포함하여 모바일 앱 사용자가 기존 매장 구매자에 비해 평균 주문 금액, 맞춤 설정 빈도가 더 높으며, 연령별 이용 양상이 뚜렷.
프로젝트 목표	1. 시간대, 매장 위치 유형, 커스텀 횟수 등의 데이터를 통해 고객의 총 지출액(total_spend)을 예측하는 회귀 모델 구축. 2. 총 지출액(매출)을 가장 잘 예측하는 핵심 요인 도출 및 '디지털 벤티 효과' 등 고객 주문 패턴에 대한 비즈니스 인사이트 확보.
데이터셋 명	starbucks_customer_ordering_patterns.csv

데이터 특징

100,000 rows × 20 columns


```
<class 'pandas.DataFrame'>  
RangeIndex: 100000 entries, 0 to 99999  
Data columns (total 20 columns):  
#   Column                Non-Null Count  Dtype    
---  -  
0   customer_id           100000 non-null    str       
1   order_id              100000 non-null    str       
2   order_date            100000 non-null    str       
3   order_time            100000 non-null    str       
4   day_of_week           100000 non-null    str       
5   order_channel         100000 non-null    str       
6   store_id              100000 non-null    str       
7   store_location_type   100000 non-null    str       
8   region                100000 non-null    str       
9   customer_age_group    100000 non-null    str       
10  customer_gender        100000 non-null    str       
11  is_rewards_member      100000 non-null    bool      
12  cart_size              100000 non-null    int64     
13  num_customizations     100000 non-null    int64     
14  total_spend            100000 non-null    float64   
15  fulfillment_time_min   100000 non-null    float64   
16  drink_category         100000 non-null    str       
17  has_food_item          100000 non-null    bool      
18  order_ahead            100000 non-null    bool      
19  customer_satisfaction  100000 non-null    int64     
dtypes: bool(3), float64(2), int64(3), str(12)  
memory usage: 13.3 MB
```

total_spend 타겟 변수 Y 설정

총 지출액 예측

Null 결측치 없음

이상치 확인




count	100000.000000
mean	14.866771
std	5.506800
min	3.510000
25%	10.837500
50%	14.170000
75%	18.180000
max	40.310000

평균 값들 보다 튀는 값(35~40) 이상치가 전체 모델을 왜곡할 가능성 있음


=> 추후 제거 필요

데이터 전처리 단계




이상치 IQR 확인 및 제거

- total_spend 컬럼의 Q1, Q3, IQR을 계산하여 이상치 범위 설정
- 하한(-0.18) 미만, 상한(29.19) 초과 데이터 제거
- 제거 후 이상치 1,415건 삭제 확인




상관관계 확인 및 시각화

- 문자열 컬럼 원핫 인코딩 후 total_spend와의 피어슨 상관관계수 계산
- 히트맵으로 시각화하여 변수 간 관계 파악
- 상관관계수 0.15 미만 변수 제거,



독립 변수(X) 및 종속 변수(Y)


- 모델이 최종적으로 예측할 정답인 '총 지출액 (total_spend)'을 종속 변수(Y)로 분리
- 총 지출액을 제외한 나머지 모든 조건(새로 만든 파생 변수 포함)을 힌트인 독립 변수(X)로 설정



새로운 DF로 저장

- 불필요한 인덱스(행 번호)를 제거하여 완성된 형태의 데이터프레임 생성

이상치 IQR 확인 및 제거



기존 시각화를 통해 대략적으로 확인한 이상치

```
# 이상치 객관적 확인 IQR
"""
1.5 * IQR(Q3 - Q1)
"""

Q1 = df['total_spend'].quantile(0.25)
Q3 = df['total_spend'].quantile(0.75)
IQR = Q3 - Q1

lower = Q1 - 1.5 * IQR
upper = Q3 + 1.5 * IQR

# 이상치가 몇 개인지 확인
outliers = df[(df['total_spend'] < lower) | (df['total_spend'] > upper)]
print(f"lower: {lower:.2f},\nupper: {upper:.2f}")
print(f"이상치 개수: {len(outliers)}")

lower: -0.18,
upper: 29.19
이상치 개수: 1415
```

IQR 분석법을 활용하여 중간범위의 1.5배를 넘어가는 이상치 제거
=> **-0.18 이하 or 29.19 이상**을 넘어가는 이상치 **1,415개** 제거 완료

상관관계 확인 및 시각화

```
# 문자열을 숫자로 바꾸기 위한 원핫 인코딩
df_encoded = pd.get_dummies(df_cleaned, columns = [
    'day_of_week',
    'order_channel',
    'store_location_type',
    'region',
    'customer_age_group',
    'customer_gender',
    'drink_category'], drop_first = True)
```


- 원핫 인코딩 : 문자열 변수 → 숫자로 변경

total_spend	1.000000
cart_size	0.900137
order_channel_Mobile App	0.501250
num_customizations	0.409149
order_ahead	0.380917

- corr 피어슨 상관계수를 통한 X, Y 상관관계 확인
(피어슨은 두 숫자 사이의 관계를 계산하기 때문에
문자열은 계산하지 못함)

상관성 높은 변수 선정

다중공선성 문제 해결을 위한
order_ahead 제거



- 히트맵 시각화 (붉은색 : 상관성 높음 / 파란색 : 상관성 낮음)
- 0.15이상의 상관성을 가진 변수를 채택

최종 독립 변수 - X, 종속 변수 - Y 설정

```
df_final = df_encoded.drop(columns = [  
    'order_id',  
    'customer_id',  
    'store_id',  
    'order_date',  
    'order_ahead',  
    'customer_age_group_25-34',  
    'customer_satisfaction',  
    'avg_satisfaction',  
    'day_of_week_Sat',  
    'region_West',  
    # 'store_location_type_Suburban',  
    'customer_gender_Prefer not to say',  
    'drink_category_Tea',  
    'day_of_week_Thu',  
    'region_Southwest',  
    'drink_category_Frappuccino',  
    'day_of_week_Sun',  
    'customer_gender_Non-binary',  
    'day_of_week_Mon',  
    'drink_category_Other',  
    'region_Southeast',  
    'drink_category_Refresher',  
    'total_orders',  
    'drink_category_Espresso',  
    'region_Northeast',  
    'day_of_week_Tue',  
    'day_of_week_Wed',  
    'customer_gender_Male',  
    # 'store_location_type_Urban',  
    'fulfillment_time_min',  
    'customer_age_group_45-54',  
    'customer_age_group_35-44',  
    'customer_age_group_55+',  
    'order_channel_Kiosk',  
    'order_channel_In-Store Cashier'], errors = 'ignore')
```

필요 없는 변수 drop

```
[  
    'order_time',  
    'is_rewards_member',  
    'cart_size',  
    'num_customizations',  
    'total_spend',  
    'has_food_item',  
    'order_channel_Mobile App',  
    'store_location_type_Suburban',  
    'store_location_type_Urban']
```

최종 독립 변수 - X

```
'total_spend',
```

최종 종속 변수 - Y

- 문제에서 명시한 변수 + 상관관계 높은 변수
=> 총 8개의 독립변수 - X

	order_time	is_rewards_member	cart_size	num_customizations	total_spend
1	08:47	False	5	0	14.48
2	08:02	True	1	3	9.52
3	05:40	False	2	1	9.32
4	15:10	True	2	1	9.55
5	07:38	False	3	1	12.24
6	11:41	True	5	1	21.13
7	06:55	True	3	0	12.95
8	19:08	True	5	6	26.33
9	06:44	True	2	2	12.17
10	12:28	True	3	1	11.11
11	14:20	False	4	4	18.41
12	17:27	False	4	1	14.45
13	14:43	True	5	5	20.69

```
df_final.to_csv('regerssion_preprocessing.csv', index=False)  
print("csv 저장 완료")
```

csv 저장 완료

regression_preprocessed.csv로 저장하여
모델에 입력할 준비 완료