

DF 봄단기 3조 프로젝트_ 4주차

분류/회귀 프로젝트

고객의 성장을 위한 전략적 솔루션을 제안합니다

- 분류 당뇨 위험군 예측 분류 모델 구축 : 미국 CDC 설문조사의 헬스케어 데이터를 기반으로
- 회귀 고객의 총 지출액 예측 회귀 모델 구축 : 스타벅스 고객의 주문 데이터를 기반으로
- 팀원 권운재, 원가형, 임수정





PART 01. 분류

분류



PROJECT INTRODUCTION

01. 프로젝트 목표

당뇨 위험군 예측하는 분류 모델 구축

02. 프로젝트 선정 배경

당뇨병은 대표적 만성 질환
조기 발견과 생활 습관 개선을 통한 예방 및 관리 중요

03. 데이터셋 명

kaggle - Diabetes Health Indicators Dataset

데이터 특징

	행(Rows)과 열(Columns)	타겟 변수 Y	Null 결측치 여부
설명	25,3680(Rows) X 22(Columns)	Diabetes_binary(0:정상, 1:당뇨위험군)	결측치 없음



분류 : 정확도, 정밀도, 재현율, F1 스코어

정확도, 정밀도, 재현율, F1 스코어 측정하기

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
```

```
# Calculate metrics for the base RandomForest model
```

```
base_accuracy = accuracy_score(Y_test, Y_pred)
```

```
base_precision = precision_score(Y_test, Y_pred)
```

```
base_recall = recall_score(Y_test, Y_pred)
```

```
base_f1 = f1_score(Y_test, Y_pred)
```

```
print(f'기본 RandomForest 모델 - 정확도: {base_accuracy:.4f}')
```

```
print(f'기본 RandomForest 모델 - 정밀도: {base_precision:.4f}')
```

```
print(f'기본 RandomForest 모델 - 재현율: {base_recall:.4f}')
```

```
print(f'기본 RandomForest 모델 - F1 스코어: {base_f1:.4f}')
```

```
# Calculate metrics for the GridSearchCV best model
```

```
grid_accuracy = accuracy_score(Y_test, Y_pred_grid)
```

```
grid_precision = precision_score(Y_test, Y_pred_grid)
```

```
grid_recall = recall_score(Y_test, Y_pred_grid)
```

```
grid_f1 = f1_score(Y_test, Y_pred_grid)
```

```
print(f'\nGridSearchCV 최적 모델 - 정확도: {grid_accuracy:.4f}')
```

```
print(f'GridSearchCV 최적 모델 - 정밀도: {grid_precision:.4f}')
```

```
print(f'GridSearchCV 최적 모델 - 재현율: {grid_recall:.4f}')
```

```
print(f'GridSearchCV 최적 모델 - F1 스코어: {grid_f1:.4f}')
```

```
기본 RandomForest 모델 - 정확도: 0.8599
```

```
기본 RandomForest 모델 - 정밀도: 0.4792
```

```
기본 RandomForest 모델 - 재현율: 0.1808
```

```
기본 RandomForest 모델 - F1 스코어: 0.2625
```

```
GridSearchCV 최적 모델 - 정확도: 0.8672
```

```
GridSearchCV 최적 모델 - 정밀도: 0.6088
```

```
GridSearchCV 최적 모델 - 재현율: 0.1043
```

```
GridSearchCV 최적 모델 - F1 스코어: 0.1781
```



기본 RandomForest 모델

정확도(Accuracy) : 0.8599

정밀도(Precision) : 0.4792

재현율(Recall) : 0.1808

F1 스코어 : 0.2625



GridSearchCV 모델

정확도(Accuracy) : 0.8672

정밀도(Precision) : 0.6088

재현율(Recall) : 0.1043

F1 스코어 : 0.1781



분류 : 정밀도와 재현율

정밀도와 재현율 비교하기


✓ 일반적으로 생명과 직결된 의료 분야에선 재현율을 우선적으로 고려

의료 분야에서 재현율의 중요성

의료 분야에서는 실제 환자를 놓치는 것이
환자가 아닌 사람을 환자로 오진하는 것보
다 중요

임계값에 따른 정밀도 및 재현율 값:

	Threshold	정밀도	재현율
0	0.000000	0.137910	1.000000
1	0.003452	0.137913	1.000000
2	0.003592	0.137915	1.000000
3	0.003621	0.137918	1.000000
4	0.003706	0.137921	1.000000
...	...	...	...
48371	0.687800	1.000000	0.000572
48372	0.694111	1.000000	0.000429
48373	0.695540	1.000000	0.000286
48374	0.697985	1.000000	0.000143
48375	0.698326	1.000000	0.000000



정밀도와 재현율이 가장 가까워지는 임계값 : 0.3059



분류 : 오차행렬(Confusion Matrix)

✓ GridSearchCV를 통해 최적화된 RandomForest 모델의 테스트 데이터 예측 결과

오차행렬 결과 분석


- True Negatives (TN) : 43,270
- False Positives (FP) : 469 (1종 오류)
- False Negatives (FN) : 6,267 (2종 오류)
- True Positives (TP) : 730

[1종 오류]

질병이 없는 사람을 질병이라고 잘못 예측하는 경우, 불필요한 추가 검사나 심리적 부담을 줄 수 있음

[2종 오류]

실제 질병이 있음에도 놓치게 되면 적절한 시기에 치료를 받지 못해 질병 악화






임계값 조정을 통한 평가 지표 변화

	분류 결정 임계값				
	0.1	0.2	0.25	0.3	0.5
정확도	0.628	0.7797	0.8167	0.8448	0.8672
정밀도	0.2568	0.3484	0.389	0.4397	0.6088
재현율	0.8959	0.6866	0.5774	0.4566	0.1043
F1	0.3991	0.4622	0.4648	0.448	0.1781

결과




- 임계값이 낮아질수록 재현율은 높아지고, 정밀도는 낮아짐
- 재현율이 중요한 의료분야에선, 재현율을 유지하면서도 적절한 정밀도를 유지
- 임계값 0.1~0.25 적정



ROC 곡선과 AUC 스코어

ROC_CURVE()



AUC 스코어 : 0.8292

✓ 기본 RandomForest 모델 평가

- 정확도 : 0.8599
- 정밀도 : 0.4792
- 재현율 : 0.1808
- F1 스코어 : 0.2625
- ROC AUC : 0.8004

✓ GridSearchCV 최적 모델 평가

- 정확도 : 0.8672
- 정밀도 : 0.6088
- 재현율 : 0.1043
- F1 스코어 : 0.1781
- ROC AUC : 0.8292

PART 02. 회귀

회귀

PROJECT INTRODUCTION

01. 프로젝트 목표

고객의 총 지출액을 예측하는 회귀 모델 구축

02. 프로젝트 선정 배경

스타벅스 고객의 주문 패턴을 분석하기 위해
생성된 시뮬레이션 데이터 : 주문 채널, 고객 연령대 등 반영

03. 데이터셋 명

kaggle - Starbucks Customer Ordering Patterns

데이터 특징

	행(Rows)과 열(Columns)	타겟 변수 Y	Null 결측치 여부
설명	100,000(Rows) X 20(Columns)	total_spend(총 지출액 예측 변수)	결측치 없음



회귀

PERFORMANCE METRICS



MAE

Mean Absolute Error

$$\sum |y_i - \hat{y}_i| / n$$

오차의 평균 절댓값
이상치에 덜 민감
해석이 직관적

MSE

Mean Squared Error

$$\sum (y_i - \hat{y}_i)^2 / n$$

오차를 제곱하여 평균
큰 오차에 더 큰 패널티
단위 해석이 어려움

RMSE

Root Mean Squared Error

$$\sqrt{\text{MSE}}$$

MSE의 제곱근
원래 단위로 해석 가능
이상치에 민감

R²

Coefficient of Determination

$$1 - SS_{\text{res}} / SS_{\text{tot}}$$

모델의 설명력 (0~1)
1에 가까울수록 좋음
이상치에 영향 받음



회귀

PERFORMANCE METRICS

DF 3조




MAE	0.8219	모델이 평균적으로 실제값에서 약 0.82 정도 빗나감
MSE	0.9355	오차를 제공한 값이라 단위가 달라져 직접 해석 어려움 → RMSE로 확인
RMSE	0.9672	MSE에 루트를 씌워 단위를 원래대로 돌린 값. 실제 오차 크기 약 0.97
R ²	0.9652	모델이 데이터 변동의 96.5%를 설명. 1에 가까운 수치로 좋은 모델

```
from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(Y_test, Y_pred)
rmse = np.sqrt(mse) # mse는 위 셀에서

print(f'MAE : {mae:.4f}')
print(f'MSE : {mse:.4f}')
print(f'RMSE : {rmse:.4f}')
print(f'R2 : {r2:.4f}')
```

MAE : 0.8219
MSE : 0.9355
RMSE : 0.9672
R² : 0.9652



회귀

OUTLIER IMPACT

방법: Y_test 앞 5개 값에 $\times 10$ 을 곱해 극단값으로 만든 뒤 지표 변화 확인

지표	이상치 x	이상치 주입 후	변화
MAE	0.82	0.85	▲ 0.03 거의 변화 없음
MSE	0.94	3.56	▲ 2.62 4배 가까이 급증
RMSE	0.97	1.89	▲ 0.92 2배 이상 급증
R ²	0.9652	0.8789	▼ 0.086 설명력 급락

회귀

OUTLIER IMPACT — CODE

```
import numpy as np

Y_test_outlier = Y_test.copy()

# 앞 5개 값을 극단적으로 바꿈 (이상치 시뮬레이션)
outlier_indices = Y_test_outlier.index[:5]
Y_test_outlier[outlier_indices] = Y_test_outlier[outlier_indices] * 10

mae_out = mean_absolute_error(Y_test_outlier, Y_pred)
mse_out = mean_squared_error(Y_test_outlier, Y_pred)
rmse_out = np.sqrt(mse_out)
r2_out = r2_score(Y_test_outlier, Y_pred)

print("[ 이상치 제거 후 ] MAE:{:.2f} MSE:{:.2f} RMSE:{:.2f} R²:{:.4f}".format(mae, mse, rmse, r2))
print("[ 이상치 포함 ] MAE:{:.2f} MSE:{:.2f} RMSE:{:.2f} R²:{:.4f}".format(mae_out, mse_out, rmse_out, r2_out))
print()
print(f"→ RMSE 변화: {rmse:.2f} → {rmse_out:.2f} (이상치에 훨씬 민감)")
print(f"→ MAE 변화: {mae:.2f} → {mae_out:.2f} (상대적으로 덜 민감)")
print(f"→ R² 변화: {r2:.4f} → {r2_out:.4f} (설명력 급락)")
```

```
[ 이상치 제거 후 ] MAE:0.82 MSE:0.94 RMSE:0.97 R²:0.9652
[ 이상치 포함 ] MAE:0.85 MSE:3.56 RMSE:1.89 R²:0.8789
```

```
→ RMSE 변화: 0.97 → 1.89 (이상치에 훨씬 민감)
→ MAE 변화: 0.82 → 0.85 (상대적으로 덜 민감)
→ R² 변화: 0.9652 → 0.8789 (설명력 급락)
```

회귀

CONCLUSION



RMSE + MAE

RMSE + MAE 같이 보기

이상치 없을 때 $RMSE(0.97) \approx MAE(0.82) \rightarrow$ 오차가 고르게 분포된 안정적인 모델
 이상치 주입 후 $RMSE(1.89) \gg MAE(0.85) \rightarrow$ RMSE와 MAE의 차이가 커지면 이상치 존재 신호로 읽을 수 있음

R^2


R^2 로 설명력 확인

0.9652 $\rightarrow$ 데이터 변동의 96.5%를 설명하는 좋은 모델
 이상치 주입 시 0.8789로 급락. 이상치가 데이터 분산을 왜곡해 모델이 설명할 수 없는 변동이 커지기 때문

MSE

MSE는 보고용 비권장

0.94 $\rightarrow$ 3.56으로 가장 크게 튀지만 제곱 단위라 "오차가 3.56이다"라고 직접 말하기 어려움
 같은 이상치 민감도를 유지하면서도 원래 단위로 해석 가능한 RMSE 사용 권장





3조 프로젝트 요약

DF 봄단기 3조 WEEK04 PROJECT

당뇨병 분류 프로젝트	RandomForest 모델	GridSearchCV 모델
정확도	0.8599	0.8672
정밀도	0.4792	0.6088
재현율	0.1808	0.1043
F1 스코어	0.2625	0.1781
ROC AUC	0.8004	0.8292

- 당뇨병과 같은 의료 분야에선 재현율이 우선시 되기에, 임계값을 조정한다면, 0.1~0.2 사이 제안

회귀 프로젝트	Linear Regression
MAE	0.8219
RMSE	0.9672
R ²	0.9652
이상치 영향	RMSE 0.97 → 1.89 (이상치 주입 시)

- R² 0.9652로 데이터 변동의 96.5%를 설명하는 안정적인 모델
- RMSE와 MAE 차이로 이상치 존재 여부 탐지 가능

DF 봄단기 3조 프로젝트_ 4주차

감사합니다

- 분류 당뇨 위험군 예측 분류 모델 구축 : 미국 CDC 설문조사의 헬스케어 데이터를 기반으로
- 회귀 고객의 총 지출액 예측 회귀 모델 구축 : 스타벅스 고객의 주문 데이터를 기반으로
- 팀원 권운재, 원가형, 임수정

