

최종 분류 문제 모델링 및 최적화

3조 분류 프로젝트 발표

분류 프로젝트 소개 및 진행 상황

1

당뇨 위험군 예측 분류 모델 구축

- 당뇨병은 대표적 만성 질환
- 조기 발견과 생활 습관 개선을 통한 예방 및 관리 중요
- Class 0 (정상) / Class 1 (당뇨)

기존 프로젝트 진행 상황

데이터 전처리, RandomForest 기본 모델, GridSearchCV, 임계값 조정, Confusion Matrix

당뇨병 분류 프로젝트	RandomForest 모델	GridSearchCV 모델
정확도	0.8599	0.8672
정밀도	0.4792	0.6088
재현율	0.1808	0.1043
F1 스코어	0.2625	0.1781
ROC AUC	0.8004	0.8292

	분류 결정 임계값				
	0.1	0.2	0.25	0.3	0.5
정확도	0.628	0.7797	0.8167	0.8448	0.8672
정밀도	0.2568	0.3484	0.389	0.4397	0.6088
재현율	0.8959	0.6866	0.5774	0.4566	0.1043
F1	0.3991	0.4622	0.4648	0.448	0.1781

클래스 불균형 확인

데이터 클래스 분포

당뇨병 아님 (0)	86.1%
------------	-------

당뇨병 (1)	13.9%
---------	-------

소수 클래스(당뇨병)가 전체의 14%
→ 심각한 클래스 불균형

기존 모델 성능 문제(임계값 = 0.5)

정확도	0.8599
-----	--------

정밀도	0.4792
-----	--------

재현율	0.1808
-----	--------

F1	0.2625
----	--------

재현율 0.18 → 실제 당뇨 환자의 82%를 놓침

성능 개선 방법


01 `class_weight = 'balanced'`

소수 클래스 가중치 부여

클래스 불균형이 있을 때 다수 클래스(diabetes 0 - 정상)에 쏠린 학습을 방지.
소수 클래스(diabetes 1 - 당뇨병)에 자동으로 더 큰 가중치를 부여해 모델이 당뇨병 환자를 더 잘 탐지하도록 학습.

```
RandomForestClassifier(  
    class_weight='balanced'  
)
```

데이터 클래스 불균형



성능 개선 방법

02 임계값 0.5 → 0.2 조정

양성 판단 기준 완화

기본 임계값 0.5 대신 0.2를 사용하면 당뇨병 양성 예측 기준이 낮아짐.

더 많은 환자를 양성으로 분류해 재현율이 크게 향상됨.


의료 데이터에서 환자를 놓치는 것(FN)이 더 위험하므로 적합한 접근.

임계값 선정 근거: WEEK04 임계값 조정 분석 결과 참고 (재현율·F1 균형 고려하여 0.2 선택)

```
(Y_probs >= 0.2).astype(int)
```

임계값 조정에 따른 평가 지표 변화

재현율을 유지하면서도 적절한 평가지표 유지하는 0.2로 조정



모델 성능 비교

모델	정확도	정밀도	재현율	F1	ROC AUC
기존 모델 (기본)	0.8599	0.4792	0.1808	0.2625	0.8004
GridSearchCV 모델	0.8672	0.6088	0.1043	0.1781	0.8292
balanced + 임계값 0.2	0.7592	0.3190	0.6577	0.4296	0.7976

재현율 0.1808 → 0.6577 (+0.477) F1 0.2625 → 0.4296 (+0.167) 당뇨병 환자 탐지율 대폭 향상

성능 개선 근거

01

클래스 불균형이 근본 원인

당뇨병 데이터는 음성(86%) >> 양성(14%)으로 불균형.
기존 모델은 다수 클래스 위주로 학습되어 재현율이 0.18에 불과했음.
정확도(0.86)는 높아 보이지만, 실제 환자의 82%를 놓치는 모델.

02

`class_weight='balanced'` 효과

소수 클래스(당뇨병)의 샘플 수에 반비례하는 가중치를 자동 부여.
모델이 당뇨병 환자를 놓치는 오류(False Negative)에 더 큰 패널티를 주어
소수 클래스를 더 적극적으로 탐지하도록 학습.

03

임계값 0.2 조정 효과


기본 임계값 0.5 → 0.2로 낮추면 양성 판단 기준이 완화됨.
의료 데이터에서 환자를 놓치는 것(FN)이 오진(FP)보다 더 위험하므로
재현율을 높이는 방향의 임계값 조정이 실질적으로 의미 있는 개선.

오분류 사례 분석

모델	FN	FP	모델	FN	FP
임계값 조정 전	12.35% (6,267명)	0.92% (469명)	임계값 0.2	4.72% (2,395명)	19.36% (9,824명)

임계값 조정을 통한 FN(실제 당뇨병 → 정상 예측) 감소, FP(실제 정상 → 당뇨병 예측) 증가

오분류 그룹 특성 비교




모델이 잘못 예측한, FN, FP의 평균을 막대그래프로 시각화
해당 8개의 변수에서 가장 큰 평균 차이를 보임

변수	FN 평균	FP 평균	차이 (FP-FN)
Income (소득 수준)	5.89	5.327	-0.563
Age (나이)	8.969	9.498	0.529
GenHlth (전반적 건강상태)	2.694	3.219	0.526
Risk_Sum (주요 위험요인 합계)	1.143	1.644	0.501
PhysHlth (신체건강 상태)	-0.032	0.376	0.408
BMI (체질량지수)	0.082	0.446	0.364
HighBP (고혈압 여부)	0.547	0.769	0.222
DiffWalk (보행 어려움 여부)	0.161	0.354	0.194

오분류 그룹 특성 비교

FN vs FP 핵심 변수 프로파일



FP 그룹 (실제 정상 → 당뇨병으로 오판)

- Age·나이 (+0.53), GenHlth·전반적 건강상태 (+0.53), Risk_Sum·주요 위험요인 합계 (+0.50) 에서 FN보다 높게 나타남

=> 당뇨병과 유사한 위험 프로파일을 가진 정상인을 모델이 당뇨병으로 오판하는 경향을 보임

FN 그룹 (실제 당뇨병 → 정상으로 누락)


- Income·소득 수준 (-0.56) 에서 FP보다 높게 나타남

=> 소득이 높은 실제 당뇨 환자를 모델이 정상으로 놓치는 경향을 보임

최종 모델 확정

분류 프로젝트	
모델	RandomForestClassifier
클래스 불균형 완화	class_weight = 'balanced' (소수 클래스 가중치 자동 부여)
임계값	0.2 (당뇨병 양성 판단 기준 완화)
재현율	0.18 → 0.65로 대폭 개선
최종 예측 모델 CSV	diabetes_predictions.csv

임계값 조정 전 : 당뇨병 예측 (1) : 13.9 % 정상 예측 (0) : 86.1 %



• 선택 근거: 실제 당뇨 환자를 놓치는 오류(FN)를 최소화하는 것이 의료 데이터에서 가장 중요하기 때문

THANK YOU

감사합니다