

DF 3조 최종 프로젝트 발표

회귀 프로젝트

발표일 : 2026.05.23 (토)

팀원 : 권윤재, 원가형, 임수정



특성 선택 (Feature Selection)

- 불필요한 특성이 포함되면 예측 정확도가 떨어지거나 과적합 발생
- 변수가 너무 적으면 과소적합, 변수가 너무 많으면 과대적합이기에 상관관계가 0.01 이하인 변수들 제거

상관관계 약한 변수 제거 전

total_spend	1.000000
cart_size	0.887672
order_channel_Mobile App	0.491512
num_customizations	0.395857
order_ahead	0.374397
has_food_item	0.208318
is_rewards_member	0.146067
customer_age_group_25-34	0.079340
customer_satisfaction	0.063871
day_of_week_Sat	0.007957
region_West	0.005830
customer_gender_Prefer not to say	0.004625
drink_category_Tea	0.003187
region_Southwest	0.003111
store_location_type_Suburban	0.002568
customer_gender_Non-binary	0.001992
order_hour	0.001846
region_Southeast	0.001795
drink_category_Frapuccino	0.001756
day_of_week_Thu	0.001677
drink_category_Other	0.000218
day_of_week_Sun	0.000026
day_of_week_Mon	-0.000259
order_minute	-0.001735
drink_category_Refresher	-0.002295
drink_category_Espresso	-0.003041
day_of_week_Tue	-0.003319
day_of_week_Wed	-0.004832
customer_gender_Male	-0.004979
region_Northeast	-0.005502
store_location_type_Urban	-0.005615
fulfillment_time_min	-0.013370
customer_age_group_45-54	-0.024072
customer_age_group_35-44	-0.044126
customer_age_group_55+	-0.106648
order_channel_Kiosk	-0.118786
order_channel_In-Store Cashier	-0.221452

Name: total_spend, dtype: float64

상관관계 약한 변수 제거 후


상관계수 0.01 이하 변수 제거 후 남은 변수들과 'total_spend'의 상관계수:

total_spend	1.000000
cart_size	0.887672
order_channel_Mobile App	0.491512
num_customizations	0.395857
order_ahead	0.374397
has_food_item	0.208318
is_rewards_member	0.146067
customer_age_group_25-34	0.079340
customer_satisfaction	0.063871
fulfillment_time_min	-0.013370
customer_age_group_45-54	-0.024072
customer_age_group_35-44	-0.044126
customer_age_group_55+	-0.106648
order_channel_Kiosk	-0.118786
order_channel_In-Store Cashier	-0.221452

Name: total_spend, dtype: float64


타겟변수 치우침 대응

스케일링을 진행한 x변수와 y값
(total_spend)의 값 분포 boxplot
시각화



타겟변수 치우침 대응

선형 회귀 모델은 정답 Y가 정규 분포를 따를 때 가장 높은 성능을 보임



변환전 | 왜도 0.442

-> 오른쪽으로 꼬리가 긴 왜도를 보임

MSE 기반 회귀모델은 큰 오차에 더 큰 패널티를 부여하므로 일부 큰 값에 학습이 치우칠 수 있음

log1p 변환 | 왜도 -0.352

log1p(x)를 사용하여 큰 값을 압축하여 데이터 범위를 축소

0 값을 안전하게 처리하기 위해 log(x)가 아닌 log1p(x)를 사용

-> 왼쪽으로 꼬리가 긴 왜도를 보임

Box-Cox 변환 | 왜도 -0.02

λ (람다)를 자동으로 탐색하여 정규분포에 가장 가까운 형태로 변환

-> 왜도가 0에 가깝게 나옴



잔차 분석

변환 전)



- 실제값과 예측값이 유사하게 분포
- 깔때기 모양의 이분산성 존재

Box-Cox 변환 후)

- 타겟 변수의 왜도는 개선
- 잔차에서 곡선 형태의 패턴이 일부 관찰
- 데이터 분포 개선과 모델 적합도는 별개의 문제임을 확인



변환전 Y값으로 LinearRegression 실행 후 잔차




Box-Cox 실행 Y값으로 LinearRegression 실행 후 잔차

최종 결론


Log1p 및 Box-Cox 변환을 통해 타겟 변수의 왜도를 감소시킴
그러나 선형회귀 성능(RMSE, R^2)은 원본 데이터가 가장 우수하게 나타남
따라서 본 프로젝트에서는 타겟 변환보다 원본 Y를 사용하는 것이 적절하다고 판단

기본 y 값




- 왜도 : 0.442
- RMSE : 0.9672
- R^2 : 0.9652

log1p 변환



- 왜도 : -0.352
- RMSE : 1.4347
- R^2 : 0.9234


Box-Cox 변환



- 왜도 : -0.20
- RMSE : 1.0673
- R^2 : 0.9576


L1, L2 규제

- Ridge(L2)와 Lasso(L1) 규제를 적용하여 과적합 완화 효과를 확인
- 세 모델 모두 유사한 성능을 보임
- Lasso가 MAE, MSE, RMSE에서 가장 낮은 오차를 기록
- 규제 적용에 따른 성능 향상은 크지 않았으나 모델 안정성 확보 가능




LinearRegression

- 변수 수가 증가할수록 과적합 위험 증가
- 변수 간 상관관계(다중공선성) 발생 가능



Ridge(L2)

- RidgeCV를 통한 최적 alpha = 1.0 선정
- $RSS + \lambda \sum w_i^2$
- 계수 크기를 제한하여 모델 안정성 향상




Lasso(L1)

- LassoCV를 통한 최적 alpha = 0.001 선정
 - $RSS + \lambda \sum |w_i|$
 - 불필요한 변수를 제거하여 모델 단순화
- > MAE, MSE, RMSE에서 미세한 오차 감소 확인

최적의 Lasso 모델과 앙상블 모델 성능 비교

최적 Lasso(L1) 모델 VS 앙상블 모델



기존 최적 Lasso 모델 성능


LASSO 모델

[Lasso 모델]

- MAE : 0.8218, MSE : 0.9352, RMSE : 0.9671, R² : 0.9652

[앙상블 모델]

- MAE : 0.8049, MSE : 0.8834, RMSE : 0.9399, R² : 0.9671



앙상블 모델 성능 비교

앙상블 모델

- 개별 모델의 예측력을 결합하여 보다 안정적이고 일반화된 성능을 확보하기 위해 단순 평균 (Simple Averaging) 기반의 앙상블 모델을 구축
- 대상 개별 모델 (5개): Linear Regression, Ridge, Lasso, RandomForestRegress, LightGBM
- 결합 방식: 각 모델이 테스트 데이터셋에 대해 예측한 값을 산술 평균하여 최종 앙상블 예측값 산출

단일 Lasso 모델 대비 앙상블 모델의 RMSE가 감소하고 R²이 상승하여, 앙상블 접근 방식을 통한 성능 개선 효과가 유의미함을 확인

개별 회귀 모델 평가

Linear Regression, Ridge, Lasso, ElasticNet, RandomForestRegressor, GradientBoostingRegressor, LightGBM, XGBoost 개별 모델

Model	MAE	MSE	RMSE	R ²
XGBRegressor	0.792024	0.845507	0.919515	0.968514
LGBMRegressor	0.791884	0.845658	0.919596	0.968509
GradientBoostingRegressor	0.793256	0.848322	0.921044	0.968409
Lasso	0.821793	0.935192	0.967053	0.965174
Ridge	0.821893	0.935382	0.967151	0.965167
LinearRegression	0.821894	0.935383	0.967152	0.965167
RandomForstRegressor	0.855278	1.049568	1.024484	0.960915
ElasticNet	2.009979	6.237123	2.497423	0.767735

XGB 하이퍼 파라튜닝

XGB 하이퍼파라튜닝 조정을 통한 성능 개선 확인

- 여러 앙상블 조합 전 기존 개인 최적 모델인 XGBRegressor 하이퍼파라튜닝 조정
- 결과 : RandomizedSearchCV를 통한 하이퍼 파라튜닝 조정을 통해 모델 개선 소폭 상승

기존 XGBRegressor

- RMSE : 0.919515
- R2 : 0.968514

튜닝된 XGBRegressor


- RMS : 0.9192
- R2 : 0.9685

여러 개별 모델과 스택킹 앙상블 비교

STEP 01

LR+Ridge+Lasso+RF+LGBM


- 개별 모델 단순 평균 방식



STEP 02

스택킹 앙상블


- 예측값을 학습해 최종 예측 수행하는 Meta 모델 훈련 방식



STEP 04

XGBRegressor + LGBMRegressor(5:5)


- 하이퍼파라미터 튜닝 된 XGB와 LightGBM 혼합
- 가장 최적의 개선된 모델 성능



STEP 03

XGBRegressor

- 두 번째로 최적화된 모델 성능



5:5 비율의 XGB와 LGBM 예측 모델로 선정

모델 개선 근거

다양한 모델 성능 비교 후 최적의 모델로 선정

1. 이상치 처리

- 타겟 변수인 total_spend 내 이상치를 IQR(Interquartile Range) 방식으로 식별 및 제거
- 이를 통해 모델이 극단적인 값에 왜곡되어 학습하는 현상 방지

2. 피처 선택

- 상관관계 약한 변수들 제거
- total_spend 데이터의 왜곡도 완화 및 정규분포에 가깝게 만들기 위해 Log1p 및 Box-Cox 변환 적용

3. 최적의 앙상블 적용

- 기존 최적 모델인 XGB를 하이퍼파라미터 조정 후 튜닝된 XGB와 LGBM 5:5 비율의 모델로 선정
- MAE : 0.7913, MSE : 0.8436, RMSE : 0.9185, R^2 : 0.9686



예측 파일